ABA 1차 프로젝트 · EDA 리포트 · 2026-10-16

EDA 리포트
보장only 고객의 추가 가입 — 데이터는 무엇을 보여주었나

보험 고객 74,776명의 스냅샷 데이터에서 "2025년에 실제로 새 상품을 가입한 고객(1,137명, 2.9%)"을 정답으로 삼고, 결측·이상치 처리 근거부터 주요 변수의 분포·관계까지 점검한 과정입니다. 계산은 모두 재현 스크립트로 실행했습니다.

데이터 TL_2.소비자.zip (보험 부분) | 프레임 T=2024년 말 · 38,932명 | 결측 NaN 0건 | 재현 스크립트 7개

74,776명

보험 고객 (거래 77,305건)
보험·증권 고객 0명 겹침

38,932명

예측 프레임의 풀
(2024년 말 기존 고객)

2.9%

2025년 실제 가입률
(양성 1,137명 · 비 1:33.2)

이 리포트에서 다루는 것 — ① 데이터 개요와 전처리 ② 결측치·이상치를 처리한 근거 ③ 주요 변수의 분포와 변수 간 관계 시각화. 모델링 성능과 상담 운용안은 `보장only_추가가입_예측_리포트.html` (4단계 리포트)에 있습니다.

1 데이터 개요

원본	`TL_2.소비자.zip` 1개 (17.5MB, utf-8-sig) — 보험·증권 거래 혼합
규모	385,019행 × 22열 — 이 중 보험 거래 77,305건 (20.1%)
고객	보험 고객 74,776명 · 증권 고객 2,681명 — **0명 겹침**(완전 분리)
행의 단위	**1행 = 고객이 보유한 상품 1건**(주보험+특약 묶음) — 고객당 1행 96.9%, 최대 5행
시간	가입 연도 1999~2025 — 88.3%가 2024~2025년(스냅샷 성격)

1-1. 열 구조 (역할별)

역할	열	비고
정의용	`cross_coverage`(담보 구성 7종) · `customer_type`(보험/증권)	담보 구성이 초기 라벨 논의의 뿌리
고객 속성 11개	연령·성별·결혼·소득·지역·직업·위험등급·신용점수·병력 등	행마다 복제되지만 고객 안에서 값 불변(검증 완료) → 고객 단위 분석은 중복 제거
상품·거래	상품명(103종)·금액 2종·가입연도·키워드 등	**가입 연도가 있어 시간 분석이 가능** — 이 데이터의 결정적 장점
식별·불가	`customer_id` · `customer_seq` · `investment_propensity`	투자성향은 보험 고객에서 100% '-' → 사용 불가

1-2. 이름이 속이는 열 4개 (실데이터로 검증)

열	실체
`product_period`	이름은 "기간"이지만 실제는 **만기 연도** — 9999(만기 없음·종신 추정)가 25% 이상
`investment_propensity`	보험 고객에서 **100% '-'** — 이 프로젝트에서 제외 확정
`customer_seq`	고객별 순번이 아님 — 유일키는 (고객ID × 상품명), 중복 2,529건

`cross_coverage`	상품 행에서 재구성하면 **83.4%만 일치** — 독립적 별도 속성 (행 데이터로 재현 불가)

1-3. 예측 프레임 (T=2024년 말) — 분석의 무대

요소	정의
행 단위	2024년 말까지 보험 상품을 보유한 기존 고객 1명 = 1행 (총 **38,932명**)
타겟	가입 연도가 2025년인 상품이 1개 이상 → 1, 없으면 0
예측 시점	2024년 말까지 아는 값(속성+보유+경과기간)으로 2025년 가입 여부를 맞힘 — 분류
제외 논리	보장 없는 고객(변액·기타 only 8,121명)은 "보장 고객의 추가 가입" 질문 밖 — 학습에서는 참여, 적용은 보장 보유자

2 전처리 과정 — 무엇을 어떻게 정리했나

전처리의 원칙은 **"원본을 훼손하지 않고, 분석 단계에서만 변형"**입니다. 실제 데이터에서 실행한 순서대로 정리했습니다.

단계	작업	내용
1	보험 부분만 추출	`customer_type='보험'` 필터 — 385,019행 → 77,305건 (증권은 다른 분석 대상)
2	고객 단위 편성	`drop_duplicates('customer_id')`로 속성 1행씩 확보 (74,776명) — 거래 내역은 별도 그룹합산
3	시간 분할	`transaction_start_year ≤ 2024` (과거) / `> 2024` (미래)로 나눠 타겟 생성 — 스냅샷을 예측 문제로 바꾼 핵심 단계
4	파생 변수 5개	경과 연수(최초가입-2024) · 납입액 합계(로그) · 상품금액 합계(로그) · 보유수 2개 이상(플래그) · 특약 포함(플래그)
5	교차 변수 1개	연령 × 결혼 — 단독 결혼이 아니라 교차로만 효과가 유지됨(가설 B 검증)

6	원-핫 인코딩	범주 8개(연령·성별·지역·소득·직업·위험등급·신용·결혼) — 트리 기반이 아니라 회귀라 명시적 인코딩 필요
7	스케일링	수치형 StandardScaler — 로그 변환과 함께 계수 해석 가능성 확보

> **최종 피처 13개** — 범주 8개 원-핫(전체 30열 규모) + 수치 4개(경과연수·납입액로그·상품금액로그·보유수2+) + 특약포함 + 연령×결혼 교차. "보유수×납입액 교차항"은 강도 재검증에서 기여 0으로 확인돼 제거했습니다(가설 F 철회).

3 결측치 — 실측 결과와 처리 근거

완전 결측(NaN): 0건 — 38,932행 모두 값이 채워져 있습니다. 실질 결측은 대체값('-', '기타') 형태로 존재합니다.

열	대체값 비율	처리	근거
`investment_propensity`	100%	**열 제외**	보험 고객에서 정보가 전혀 없음 — 채우거나 인코딩할 것이 없음
`occupation_group`	10.3%	'기타'를 하나의 범주로 유지	버리면 4,020명의 정보 손실 — 대신 "직업 미분류"라는 자체 정보로 취급
`disease_history`	7.7%	'기타' 유지 후 **피처에서 제외**	가설 검증에서 방향이 두 프레임 사이에 뒤집힘(T23 +6.9 vs 5.3 / T24 3.2 vs 2.7) — 신호로 불안정, 모델 오염 위험이 제거 이득보다 큼
`region`	5.4%	'기타' 유지	지역 신호는 강건(대구 0.8% vs 경기 3.8%) — 지역 '기타'도 별도 범주로 정보 유지
`credit_rating`	0.8%	'기타' 유지	비율이 작고 신용 300점대만이 유일한 하단 신호 — '기타' 영향 미미

결측 처리의 통일 규칙 — 어떤 열에서든 "'기타'를 제거·보간하지 않는다". 이유: ① 이 데이터의 결측은 무작위가 아니라 **정보의 유무 자체**(예: 직업 미상)일 수 있고 ② 보간하면 고객 속성의 "사실"을 만들어내게 됨 ③ '기타'를 별도 범주로 두면 결측 여부가 스스로 예측 신호가 될 수 있음.

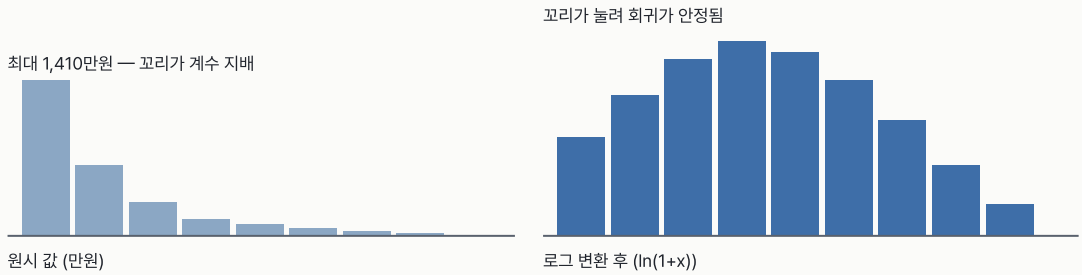
계산 규율 — 가설 검증·EDA 집계에서 '기타'를 빼고 셀을 셀 때마다 개수를 명시했습니다(예: 신용 '기타' 319명 제외 후 비교). 결측 처리 방식이 비율에 직접 들어가지 않게 하기 위한 규칙입니다.

4 이상치 — 실측 결과와 처리 근거

변수	중앙값	최대	IQR 초과	판정
경과 연수	0년	25년	8,964건	**오경보** — 0이 77%라 IQR 상한이 0이 됨. 실제 이상치 아님
보유 상품 수	1개	5개	680건(1.7%)	**정상 소수 집단** — 오히려 가장 강한 양성 신호(4.1배)
납입액 합계	70만원	1,410만원	1,550건 (4.0%)	우측 꼬리 — **로그 변환**으로 처리
상품금액 합계	5,000만 원	6억원	1,464건 (3.8%)	우측 꼬리 — **로그 변환**으로 처리

4-1. 왜 "자르지 않고" 로그 변환인가 — 근거 3개

#	근거
1	**찾으려는 대상이 꼬리에 있음** — "많이 보유·많이 납입"하는 고객이 바로 가설 A(반복 구매 4.1배)의 주인공. 절단하면 우리가 찾는 고객을 지우는 것
2	**금액 변수는 본질적으로 로그 정규 근사** — 중앙값 70만원 vs 최대 1,410만원(20배)의 꼬리는 자연스러운 금액 분포. 원시 값 그대로 회귀에 넣으면 계수가 꼬리에 지배당함
3	**오경보와 진짜 이상치를 구분** — 경과 연수·보유수의 "IQR 초과"는 0/1이 다수인 분포의 수학적 부산물(오경보)이고, 금액의 초과는 진짜 꼬리. 성격이 다른 두 종류에 같은 절단을 쓰면 안 됨

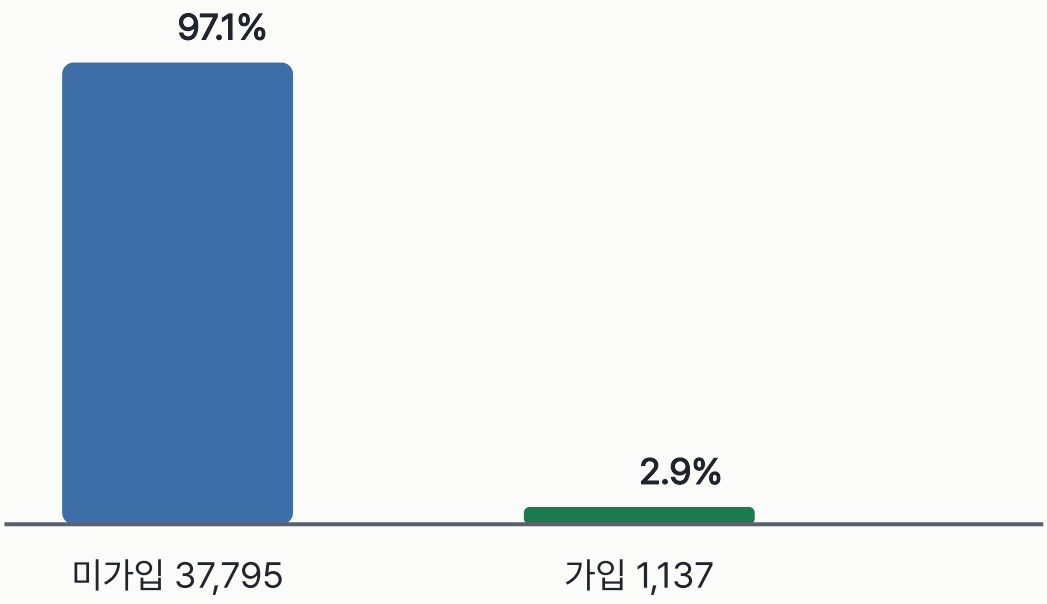


개념도 — 납입액 합계·상품금액 합계의 원시 분포(좌)와 로그 변환 후(우). 실제 히스토그램 그림은 `output/EDA_T2024_수치형분포.png`

> **확인된 사실(해석 보류)** — 두 프레임 모두에서 납입액 중앙값이 재확인됐습니다: 대용라벨 프레임(보장 포함 66,655명)에서 확장자 50만원 vs 보장only 100만원, 현 T=2024 프레임에서는 미가입 70만원 vs **가입 200만원**(1개 보유 70만원 vs 2개 이상 190만원) — **가입한 고객의 납입액이 더 크다**는 방향은 양쪽에서 일관됩니다. `transaction_amt` 의 정의(월 납입액? 기타 금액?)가 데이터 설명 없이는 확정되지 않아 절대 금액의 해석은 보류 중 — 정의 확보가 미실행 검증 후보로 기록돼 있습니다. `scripts/step4_pay_median_recheck.py`

5 주요 변수의 분포

5-1. 타겟 분포 — 심한 불균형 (1 : 33.2)



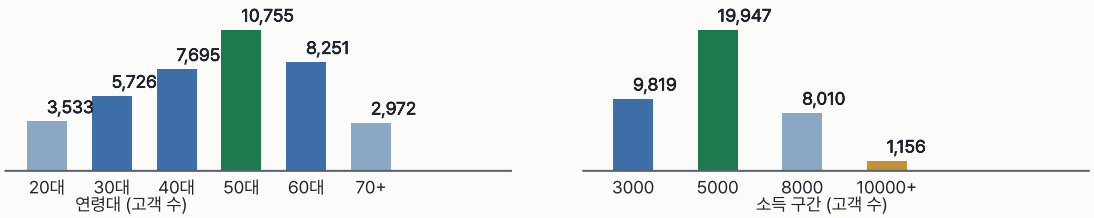
타겟(2025년 실제 가입 여부) — 무조건 "미가입" 찍어도 정확도 97.1% → 평가는 반드시 상위 k명 가입률(리프트)로.

불균형의 의미:

항목	값
양성(가입) 고객	1,137명
클래스 비	1 : 33.2
학습 처리	balanced 가중치
평가 방식	리프트(전체 2.9% 대비)

5-2. 고객 속성 분포 (38,932명)

변수	분포 특징
연령대	50대 27.6% · 60대 21.2% · 40대 19.8% · 30대 14.7% · 20대 9.1% · 70대 이상 7.6% — 중장년 중심
성별	여 52.8% · 남 47.2% — 거의 균형
결혼	기혼 79.9% · 미혼 20.1% — 기혼 편중
소득	5000만원미만 51.2% · 3000만원미만 25.2% · 8000만원미만 20.6% · 10000만원이상 3.0% — 하위 구간 쏠림
지역(10개)	경기도 30.7% · 서울 16.9% · 경상도 11.1% · 충청도 9.7% · 전라도 7.5% · 부산 6.8% · 인천 6.5% · '기타' 5.4% · 대전 3.1% · 대구 2.4% — 수도권·경상 쏠림
위험등급	A 65.9% · B 18.7% · C 8.5% · D 3.7% · E 3.1% — A 편중
신용	900이상 58.6% · 800대 24.8% · 700대 12.2% · 300대 3.6% · '기타' 0.8%
보유 상품 수	1개 98.3% · 2개 1.7% · 3개+ 극소 — 단일 보유가 압도적
경과 연수	0년(2024 가입) 77.0% · 1년 11.4% · 2년+ 11.6% — 최근 가입 집중



연령대(좌)·소득 구간(우) 고객 수 분포 — 연령은 50대 정점, 소득은 5000만원미만 최다. 실제 그림: `output/보장only_EDA_주요축_확장비율.png`

6 변수 사이의 관계

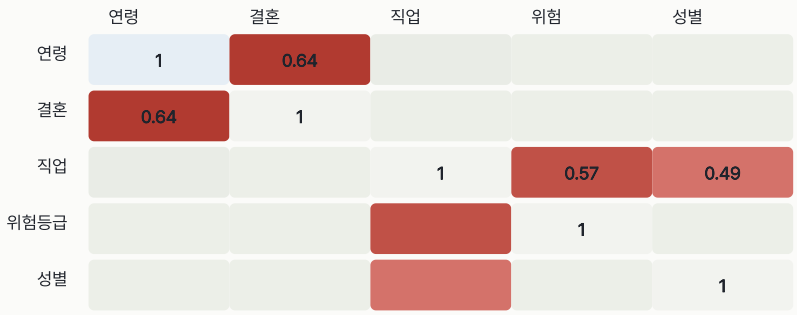
6-1. 타겟과의 관계 — 개별 신호는 전부 미약

변수	타겟과의 상관	해석
보유 상품 수	**+0.070** (최고)	가장 강해도 0.07 — 단일 변수로 안 갈라짐
납입액 (로그)	+0.050	보조 신호
상품금액 (로그)	+0.020	약함
경과 연수	+0.004	무상관 — 가설 H2 평평함과 일치
범주 8개 (크라메르 V)	0.018~0.047	전부 미미 — **모델의 조합**이 필요한 구조

6-2. 변수끼리의 관계 — 겹치는 쌍 3개 (다중공선성 주의)

쌍	크라메르 V	의미와 처리
연령 × 결혼	**0.642**	나이 많으면 기혼 — 그래서 "결혼 단독"이 아니라 **연령×결혼 교차**로 피처 설계
직업 × 위험등급	0.572	정보 겹침 — 둘 다 원-핫으로 유지하되 계수는 "방향 참고"로만 해석

성별 × 직업	0.490	같음



범주형 변수 간 크라메르 V — 붉을수록 겹침이 큼. 연령×결혼(0.64)이 최대. 전체 히트맵: `output/예측_T2024_상관히트맵.png`

6-3. "가르는 힘" 종합 — EDA가 말한 것

구분	내용
복제 신호 6개	보유수2+ 4.1배 · 기혼(40대 이상) · 여성 · 지역(대구 0.8% vs 경기 3.8%) · 소득 역U(5000 정점) · 신용 300점대 최저 — **두 프레임(T23/T24) 모두 재현**
소멸 신호 2개	갱신형 보유 · 경과 기간 — T=2023에서만 나타났다가 T=2024에서 사라짐(코호트 얽힘) → 제외
무관 2개	병력(방향 뒤집힘) · 결혼 단독(연령에 흡수) → 제외·교차화

> **EDA의 한 문장 결론** — 개별 속성은 어떤 것도 라벨을 강하게 가르지 않지만(최고 +0.07), **조합**(특약 보유 + 보유수 2개 이상 + 기혼 중년 + 중간 소득)은 기준선의 3~4배 농도를 만듭니다. 이것이 "기초 모델이 필요한 이유"이며, 실제 모델이 판정(상위 1,000명 8.2%)을 충족시킨 근거입니다.

7 재현 경로

데이터 검증	`scripts/step1_verify_*.py`
EDA 점검	`scripts/step2_eda.py · eda_t2024_*.py`

가설 검증	`scripts/step3_hypothesis_*.py · new_hypothesis_*.py`
그림	`output/EDA_T2024_*.png · 예측_T2024_*.png`
확정 문서	`1_2단계_확정본.md`

모든 수치는 재현 스크립트 실행값이며, '기타' 범주 제외 개수는 각 표에 명시했습니다. · EDA 리포트 · 2026-10-16